

BÁO CÁO TỔNG QUAN DỮ LIỆU

Đánh giá bộ dữ liệu công khai phục vụ hiệu chỉnh simulator thị trường gọi xe

Đề tài: *Supply-Aware Promotion Uplift*

Dữ liệu: NYC TLC HVFHV 07/2026 (20,9 triệu chuyến Uber/Lyft); NYC yellow taxi 01/2015 có toạ độ (12,7 triệu chuyến); báo cáo tổng hợp tháng của TLC; Hillstrom (RCT uplift để đối chứng)

Nhóm thực hiện: Nguyễn Huy Hoàng, Phan Văn Tình
Người hướng dẫn: Nguyễn Bảo Long

Tóm tắt

- (1) **Dữ liệu trong tài liệu tham khảo.** Đã kiểm tra 31 bài báo và blog. Trong mảng gọi xe, bộ công khai *duy nhất* được dùng là NYC TLC Trip Record Data (4 bài). Mảng uplift dùng Hillstrom và Criteo; hai bộ này có can thiệp ngẫu nhiên nhưng không có phía cung. **Không bộ nào** có đồng thời voucher, trạng thái cung và $V(\pi)$.
- (2) **Bộ được chọn: NYC TLC**, gồm hai bộ con. Yellow 01/2015 có toạ độ là đúng bộ Farias và cộng sự đã dùng. HVFHV 07/2026 là bộ công khai duy nhất có mốc *đặt xe* $\rightarrow$ *tài xế tới* $\rightarrow$ *đón*, tức đo được ETA.
- (3) **Có:** thời điểm cầu, ETA, thời gian chờ và chờ, quãng đường, giá, zone hoặc toạ độ. **Thiếu:** voucher, đặc trưng rider, số tài xế rảnh theo cell, request bị huỷ, hệ số surge.
- (4) **EDA nổi bật:** ETA trung vị 3,4 phút; 9,8% chuyến chờ trên 10 phút; tỷ số đỉnh/đáy theo giờ 1,92 (simulator dùng 2,1). Cầu lệch theo không gian mạnh hơn nhiều so với zone_factor. Khoảng 24% biến động ETA là riêng từng ngày. Trong cùng zone $\times$ thứ $\times$ giờ, cầu cao hơn 10% thì ETA cao hơn khoảng 3,5%.
- (5) **Kết luận:** NYC TLC **không** dùng để huấn luyện hay đánh giá uplift ($\hat{\tau}$, Qini, $V(\pi)$), nhưng **dùng được để hiệu chỉnh simulator**: neo trực tiếp các tham số phía cầu và thời gian, và so khớp moment cho các tham số độ căng.

Mục lục

1	Đề tài cần gì từ dữ liệu	2
2	Dữ liệu được dùng trong các bài báo tham khảo	2
3	Bộ dữ liệu được chọn: NYC TLC Trip Record Data	3
4	Đối chiếu trường dữ liệu với nhu cầu	4
5	Phân tích khám phá dữ liệu	5
6	Cách sử dụng dữ liệu cho đề tài	10
7	Kết luận	12
8	Giới hạn và rủi ro	12

A Tái lập kết quả

12

1. Đề tài cần gì từ dữ liệu

Theo đề bài, đặc tả simulator (SPEC.md) và hai buổi họp với mentor, một bộ dữ liệu dùng được trọn vẹn cho đề tài phải có đủ sáu nhóm biến trong Bảng 1.

Bảng 1: Các nhóm biến đề tài cần từ dữ liệu

Nhóm	Biến cần	Dùng cho
Rider	Định danh, covariate trước can thiệp (freq, price_sens, tenure, patience, ...)	Ước lượng $\tau(x)$, Qini
Can thiệp	Voucher có/không, mức giảm, lát ngẫu nhiên hoá	Uplift, confounding
Kết quả	Request, completed, huỷ	$\tau_{\text{request}}, \tau_{\text{completed}}$
Trạng thái thị trường	Cầu, cung (tài xế rảnh/bận), ETA, utilization theo cell (zone/hex $\times$ giờ)	Trục thứ ba “cung–cầu”
Không gian – thời gian	Toạ độ hoặc ô hex, khung giờ	Chia cell, switchback
Chính sách thật	$V(\pi)$ dưới nhiều chính sách	Ground truth

Mentor đã lưu ý rằng dữ liệu công khai thường thiếu đặc trưng cá thể, thời gian thực tế và biến can thiệp, nên hướng đi bắt buộc là xây dựng môi trường mô phỏng. Đề bài cũng xác định $V(\pi)$ về bản chất không quan sát được trên dữ liệu thật. Vì vậy câu hỏi đúng không phải “bộ nào thay được simulator”, mà là “**bộ nào giúp simulator giống thật hơn, và ở tham số nào**”.

2. Dữ liệu được dùng trong các bài báo tham khảo

Đã kiểm tra 31 tài liệu: danh sách đọc trong đề bài, các bài mở rộng trong problem.md và bài Peng–Ye–Zheng. Mỗi bài được đọc toàn văn nếu truy cập được, và mỗi trích dẫn được đối chiếu lại bằng tìm kiếm chuỗi. Chi tiết và trích dẫn nguyên văn nằm ở Phụ lục A của thư mục dữ liệu (phu_luc_A_bai_bao_va_du_lieu.md).

Bảng 2: Dữ liệu dùng trong mảng cơ chế thị trường gọi xe và thiết kế thí nghiệm

Bài	Dữ liệu dùng	Công khai
Farias, Li, Peng & Zheng – NeurIPS’22 [2]	Simulator Manhattan sinh rider từ NYC TLC yellow taxi ngày 11/01/2015 (file cấu hình trong code nạp 10/01/2015); khoảng 300 nghìn request và 7 nghìn tài xế mỗi ngày	Có
Hu & Wager – switch-back [3]	Dùng lại simulator của Farias trên dữ liệu yellow taxi năm 2015	Có
Peng, Ye & Zheng – EC’25	Simulator định giá Manhattan; code dùng NYC yellow 09/2024 (2,98 triệu chuyến, gán nút đường OSM)	Có
Bright, Delarue & Lobel – MS 2025	Dữ liệu taxi và gọi xe công khai của New York (06/2023, khoảng 10 triệu cặp đi–đến)	Có
Castillo, Knoepfle & Weyl [4]	Dữ liệu nội bộ Uber, Manhattan 12/2016–02/2017: phút tài xế rảnh/đi đón/chờ, lượt mở app, request, huỷ, surge	Không
Blake & Coey – EC’14	Thí nghiệm e-mail của eBay, 4,9 triệu người dùng	Không
Holtz và cộng sự – MS 2025	Meta-experiment phí trên Airbnb, 2,6 triệu listing	Không
Chamandy (Lyft, 2016) [6]	Simulator phát lại phiên app lịch sử	Không
Bojinov, Johari [5]; Li; Wager & Xu; Zhu, Ke & Wang	Chỉ mô phỏng hoặc mô hình	–

Bảng 3: Dữ liệu dùng trong mảng uplift, HTE và đánh giá chính sách

Bộ dữ liệu	Bài dùng	Có phía cung
Hillstrom (64.000 khách, e-mail 3 nhánh)	Zhang–Li–Liu 2021; Yang–Liu–Huang 2026; E3IR 2024; Diemert 2018	Không
Criteo Uplift (13,98 triệu dòng)	Yadlowsky và cộng sự 2025; Zhou và cộng sự (DHCL) 2023; Diemert 2018	Không
RCT khác (bầu cử, GAIN, ...)	Künzel; Athey & Wager; Cinelli & Hazlett	Không
Nội bộ hoặc mô phỏng	Gutierrez & Gérardy; Kennedy; Zhao & Harinen (Uber); LBCF (Kuaishou); CanniUplift (Alibaba)	Không

Ba nhận định rút ra:

1. Trong mảng gọi xe, **NYC TLC là chuẩn chung công khai**: mọi bài dựng simulator trên dữ liệu thật công khai đều dùng bộ này. Lyft dựng simulator trên dữ liệu nội bộ.
2. **Không bài nào công bố dữ liệu về trạng thái cung**. Các biến này chỉ có trong dữ liệu nội bộ Uber của Castillo và cộng sự. Mọi simulator dựa trên NYC đều phải tự sinh phía cung, giống cách simulator của nhóm đang làm.
3. **Các bài trên đều không dùng HVFHV**, dù đây là bộ con của cùng nguồn TLC và là nơi công khai duy nhất có request_datetime và on_scene_datetime. Vì vậy báo cáo phân tích thêm HVFHV bên cạnh bộ yellow của Farias.

3. Bộ dữ liệu được chọn: NYC TLC Trip Record Data

3.1. Nguồn và cách truy cập

Bảng 4: Thông tin nguồn dữ liệu NYC TLC

Đơn vị phát hành	NYC Taxi & Limousine Commission (TLC) [1]
Định dạng	Parquet theo tháng, công bố trễ khoảng 2 tháng. Tháng mới nhất hiện có là 07/2026
Truy cập	Tải trực tiếp, không cần đăng ký, qua CDN <code>d37ci6vzurychx.cloudfront.net/trip-data/</code>
Điều khoản	Dữ liệu công khai của thành phố; TLC không bảo đảm độ chính xác. Khi trích dẫn ghi rõ “NYC TLC” và tháng dữ liệu
Bản có toạ độ	TLC CDN chỉ còn taxi zone từ 2011. Toạ độ GPS của yellow 2009 – 06/2016 còn trên Azure Open Datasets
Dữ liệu kèm	Bảng tra taxi zone, shapefile zone (EPSG:2263), báo cáo tổng hợp tháng (số xe, giờ hoạt động)

3.2. Các bộ con và hai file đã phân tích

Bảng 5: Các bộ con của NYC TLC và vai trò trong đề tài

Bộ con	Thời gian	Điểm đặc biệt	Vai trò
HVFHV (Uber, Lyft)	02/2019 – nay	Thời điểm đặt xe, tài xế tới, đón, trả; giá; tiền tài xế	Bộ chính để hiệu chỉnh
Yellow taxi	2009 – nay	Xe vẫy; toạ độ GPS tới 06/2016 (bản Azure)	Đúng bộ Farias dùng; gán hex trực tiếp
Green taxi	2013 – nay	Như yellow, ngoài Manhattan	Phụ
FHV thường	2015 – nay	Không có giá, không có giờ đặt	Không dùng

- fhvhv_tripdata_2026-07.parquet: 20.921.249 dòng, 25 cột, 511 MB; Uber 72,7%, Lyft 27,3%; không có dòng trùng; khớp số chuyến/ngày của báo cáo tổng hợp TLC (674.877).
- Yellow 01/2015 (Azure, 20 file): 12.744.563 dòng, 21 cột, 414 MB; có tọa độ đón/trả; cột zone trống 100% vì năm 2015 chưa có zone.

4. Đối chiếu trường dữ liệu với nhu cầu

Bảng 6: Trường có sẵn trong hai bộ con so với nhu cầu của đề tài


Đề tài cần	HV FHV 2026	Yellow 2015	Hệ quả
Thời điểm phát sinh cầu	Có (request_datetime)	Không	HV FHV đo được thời gian chờ
ETA, thời gian chờ	Có: $ETA = on_scene - request$; chờ = pickup – request	Không	Neo pickup_w0, độ căng
Thời gian chờ, quãng đường	Có	Có	Neo ride_len_L, tốc độ
Vị trí	263 taxi zone	Tọa độ GPS	Zone → hex cần giả định
Giá	Giá cơ bản, tiền tài xế	Giá đồng hồ	Quy đổi voucher ra tiền
Voucher / khuyến mãi	Không	Không	Không neo được alpha
Đặc trưng rider	Không	Không	Không train uplift, không tính Qini
Request bị hủy	Không (chỉ chuyến hoàn thành)	Không	“Cầu” quan sát được là throughput đã bị cắt ở trần cung
Tài xế rảnh theo cell Surge	Không Không có trường	Không –	Cung chỉ suy ra bằng mô hình Chỉ suy gián tiếp từ giá

Chất lượng dữ liệu

Từ điển dữ liệu sai về on_scene_datetime. Từ điển ghi trường này chỉ có cho xe lăn, nhưng tháng 07/2026 nó có cho **100%** chuyến; chỉ trước khoảng 03/2025 mới trống với chuyến Lyft. Các dòng bất thường đều nhỏ: pickup trước request 1,18%; on_scene trùng pickup 4,8%; on_scene trước request 1,75%; giá ≤ 0 là 0,08%. Bộ lọc chuẩn (loại chuyến xe lăn, đi chung, Access-A-Ride; giữ $0 \leq \text{chờ} < 60$ phút) giữ lại **97,2%** số chuyến.

5. Phân tích khám phá dữ liệu

5.1. Phân phối các đại lượng chính (HVFHV 07/2026)



Hình 1: Phân phối thời gian chờ, ETA, thời gian chờ, quãng đường và giá (HVFHV 07/2026)


Bảng 7: Thống kê mô tả các đại lượng chính

Đại lượng	Trung vị	Trung bình	p90	Nhận xét
Chờ tổng (đặt → đón), phút	4,42	5,40	9,93	9,8% chờ > 10 phút (Uber 11,1%, Lyft 6,4%)
ETA (đặt → tài xế tới), phút	3,37	4,32	8,72	Gồm cả thời gian ghép chuyến
Tài xế chờ khách ra xe, phút	0,75	1,06	2,02	
Thời gian chờ, phút	15,6	19,3	36,8	Đuôi dài: chuyển sân bay
Quãng đường, dặm	2,84	4,87	11,1	
Tốc độ, mph	11,4	13,4	23,4	
Giá cơ bản, USD	19,1	27,2	54,2	6,5 USD/dặm (trung vị)
Tài xế nhận / giá cơ bản	0,76	0,80	1,07	15,2% chuyển tài xế nhận nhiều hơn

Ở khoảng 1/7 số chuyến, nền tảng trả tài xế nhiều hơn giá cơ bản khách trả. Đây có thể là hệ quả của quy định lương tối thiểu tài xế ở NYC (chưa kiểm chứng) và là chi tiết cần lưu ý khi xây hàm giá trị của simulator.


5.2. Thời gian: cầu và ETA theo ngày, giờ, thứ

Trung bình có 656 nghìn chuyến/ngày, dao động từ 562 nghìn (thứ Ba 07/07) đến 792 nghìn (thứ Bảy 18/07); chu kỳ tuần rõ, thấp nhất thường vào thứ Hai và cao nhất vào thứ Bảy. **Ngày thường** có hai đỉnh lúc 8h (38,0 nghìn chuyến/giờ) và 17h (38,2 nghìn). Trong khung 6–23h của simulator, hệ số giờ đi từ 0,62 đến 1,19, tức **tỷ số đỉnh/đáy 1,92**, gần với 2,1 mà simulator đang dùng. **Cuối tuần** không có đỉnh sáng; cầu tăng đều tới khuya, tỷ số đỉnh/đáy 2,66.




Hình 2: Hồ sơ cầu theo giờ, ngày thường và cuối tuần (HVFHV 07/2026)

Theo giờ, **ETA ngày thường khá phẳng**: trung vị 2,7–3,9 phút trong 6–23h. Có hai chỗ nhô lên: đỉnh sáng (ETA 3,9 phút, 11,6% chuyến chờ trên 10 phút) và **đêm cuối tuần** (23h thứ Bảy/Chủ nhật: ETA trung vị 5,2 phút, 24% chuyến chờ trên 10 phút). Như vậy, ở mức trung bình theo giờ, cung (cùng với giá) theo kịp cầu khá tốt; độ căng thật tập trung ở một số khung giờ, ngày và khu vực cụ thể.



Hình 3: ETA và tỷ lệ chờ trên 10 phút theo giờ

5.3. Không gian: zone, quận và so với ô hex



Hình 4: Mật độ chuyến và ETA theo taxi zone (HVFHV 07/2026)

- **Cầu lệch rất mạnh theo không gian.** Manhattan chiếm 35,5% số chuyến trên 7% diện tích (3.946 chuyến/km²/ngày), trong khi Staten Island chỉ có 71. Một phần tư số zone chiếm 54% số chuyến; đứng đầu là hai sân bay (LaGuardia 12,9 nghìn, JFK 11,5 nghìn chuyến/ngày). Chuẩn hoá theo trung bình như zone_factor, khoảng p10–p90 là **0,16–2,06**, rộng hơn nhiều so với 0,6–1,6 của simulator.
- **ETA lệch theo chiều ngược lại:** trung tâm có ETA thấp (Manhattan trung vị 2,9 phút), ngoại vi có ETA cao (hơn 5 phút). Tỷ lệ chờ trên 10 phút theo zone đi từ 4,2% (p5) đến 21,8% (p95). Đây là hiệu ứng mật độ: nơi đông cầu thì cung cũng dày.

Bảng 8: Kích thước taxi zone so với ô H3

	Số zone	Tổng km ²	Diện tích trung vị	Ô H3 gần nhất
Toàn thành phố	263	792,9	2,14 km ²	Giữa res 7 (5,16 km ²) và res 8 (0,74 km ²)
Manhattan	69	58,9	0,69 km²	≈ res 8 (0,74 km ²)

5.4. Quan hệ cung–cầu

Đơn vị phân tích là cell zone × ngày × giờ (6–23h), giống simulator: tổng cộng 142.319 cell.

(a) Biến động cấu trúc và biến động riêng từng ngày.


Bảng 9: Phân rã phương sai theo các mức cấu trúc

Đại lượng	R ² zone	R ² zone × giờ	R ² zone × thứ × giờ	Riêng từng ngày
log số chuyến	0,80	0,89	0,96	SD 0,12 (ngoài phần Poisson)
log ETA trung vị	0,34	0,53	0,74	≈ 24% phương sai
Tỷ lệ chờ > 10 phút	0,27	0,46	0,68	≈ 28% phương sai

Cầu gần như hoàn toàn dự đoán được từ zone × thứ × giờ, nhưng khoảng **một phần tư biến động của ETA là riêng từng ngày** (thời tiết, sự kiện, số taxi xế online). Trong simulator hiện tại, cung và cầu chỉ phụ thuộc


(zone, giờ); dữ liệu cho thấy nên thêm **shock cung theo ngày**.

(b) Độ co giãn của ETA theo cầu. So các ngày trong cùng zone × thứ × giờ (Hình 5): ngày có nhiều chuyến hơn 10% thì ETA cao hơn khoảng **3,5%** (độ co giãn +0,35) và tỷ lệ chờ trên 10 phút cao hơn khoảng 0,8 điểm phần trăm. Độ co giãn tăng theo độ đông: +0,21 ở quý vắng nhất, **+0,50 ở quý đông nhất**, +0,59 với cell từ 200 chuyến. Đường cong **cong lên**, là dấu hiệu của cơ chế mà simulator mô hình hoá bằng kappa_eta và wild goose chase. Ngược lại, so **cắt ngang** giữa các zone cho hệ số **−0,07**, vì cung đi theo cầu. Do đó **không được hiệu chỉnh độ căng từ mặt cắt ngang**. Đây là tương quan, không phải nhân quả, và “cầu” ở đây là chuyến hoàn thành nên độ co giãn thật có thể còn lớn hơn.



Hình 5: ETA và tỷ lệ chờ trên 10 phút khi cầu lệch khỏi mức thường của cùng zone × thứ × giờ

(c) Cung chỉ suy ra được bằng mô hình. Áp định luật Little cho từng phút, số xe đang bận (từ lúc đặt tới lúc trả khách) ở ngày thường đi từ 2,5 nghìn (3h) lên 7,1 nghìn (6h), 14,9 nghìn (8h) và **17,1 nghìn (17h)**; đây là cận dưới của số xe đang trực. Báo cáo tổng hợp TLC cho 61.044 xe/ngày, mỗi xe 6,4 giờ, tức trung bình khoảng 16,3 nghìn xe trên đường.



Hình 6: Số xe đang bận theo giờ (định luật Little) và utilization toàn thành phố theo tháng

Bảng 10: Các chỉ số utilization toàn thành phố


Chỉ số (toàn thành phố)	Giá trị
Tỷ lệ thời gian có khách, 07/2026 (từ file chuyển; công thức TLC cho 0,547)	0,54
Tỷ lệ thời gian bận, kể cả đi đón và ghép chuyển, 07/2026	0,69
Utilization theo tháng, 06/2017 – 07/2026	Trung bình 0,58; thấp nhất 0,44 (04/2020, COVID); cao nhất 0,67

Con số 0,69 tương ứng với $utilization = (supply - free)/supply$ của simulator, hiện có `util_lag` từ 0,41 (p10) tới 1,00 (p90). Dữ liệu thật chỉ cho mức trung bình toàn thành phố; phân phối theo cell phải suy ra bằng mô hình.

(d) Giá theo giờ. Sau khi khử quãng đường và thời gian, chỉ số giá theo giờ ngày thường chỉ dao động 0,97–1,02. Nếu có surge thì nó tập trung ở không gian và thời điểm hẹp, không thấy ở trung bình theo giờ.

5.5. Bộ yellow taxi 01/2015 của Farias và cộng sự

Tháng 01/2015 có 12,74 triệu chuyến (411 nghìn/ngày, so với 675 nghìn/ngày của HVFHV 2026). Ngày 11/01/2015 (Chủ nhật) ghi trong bài Farias có 419.628 chuyến, trong đó 375.708 chuyến đón ở Manhattan (89,5%) và 339.581 chuyến trong nội Manhattan, cùng cỡ với “khoảng 300 nghìn request” mà bài báo nêu. **Bão tuyết Juno** (26–27/01/2015) làm số chuyến rơi còn 230 nghìn rồi 135,5 nghìn: một cú sốc cung–cầu tự nhiên có sẵn trong dữ liệu. Ngày thường ở Manhattan có một hôm lúc 16h, trùng giờ đổi ca taxi vàng; đây là ví dụ thật về số chuyến bị giới hạn bởi cung. Về chất lượng: 1,9% chuyến có tọa độ đón bằng 0 và quãng đường có giá trị lỗi.



Bảng 11: Mật độ chuyến theo độ phân giải H3, Manhattan, 11/01/2015

H3	km²/ô	Số ô	Trung vị	p90
res 7	5,16	22	206	1.923
res 8	0,74	104	42	480
res 9	0,11	532	14	83

Trung vị và p90: số chuyến/ô/giờ trong khung 6–23h.

Vì có tọa độ, bộ này gán thẳng vào ô H3 mà không cần giả định phân bố trong zone. Simulator hiện có `1am_base` = 174 rider mỗi cell; với tỷ lệ hoàn thành khoảng 0,15 thì mỗi cell có khoảng 26 chuyến, nằm giữa res 8 và res 9 của Manhattan năm 2015 (chỉ tính taxi vàng).

Hình 7: Số chuyến theo ô H3 res 8 tại Manhattan, ngày 11/01/2015

5.6. Đối chứng: bộ dữ liệu uplift Hillstrom

Hillstrom là bộ uplift được dùng nhiều nhất trong danh sách đọc: 64.000 khách chia đều ngẫu nhiên vào 3 nhánh, cân bằng tốt về covariate. Bộ này có đúng thứ NYC thiếu (can thiệp ngẫu nhiên, outcome, covariate cá nhân) nhưng thiếu đúng thứ NYC có (thị trường, cung, thời gian chờ). Criteo Uplift (13,98 triệu dòng, 12

feature ẩn danh, 85% treated) cũng cùng loại. **Không có bộ công khai nào có cả hai.**

Bảng 12: Kết quả các nhánh của Hillstrom (KTC: khoảng tin cậy)

	Không e-mail	E-mail nam	E-mail nữ
Tỷ lệ ghé web	10,6%	18,3%	15,1%
Tỷ lệ mua	0,57%	1,25%	0,88%
ATE lên tỷ lệ ghé web (KTC 95%)	–	+7,7 điểm % (7,0–8,3)	+4,5 (3,9–5,2)

6. Cách sử dụng dữ liệu cho đề tài

6.1. Ánh xạ tham số simulator với các mốc neo từ NYC

Bảng 13: Tham số SimConfig và mốc neo từ dữ liệu NYC 07/2026

Tham số	Hiện tại	NYC 07/2026	Cách dùng
hour_factor[h]	1,0–2,1 (đỉnh/đáy 2,1)	Ngày thường 0,62–1,19 (đỉnh/đáy 1,92; đỉnh 8h và 17h); cuối tuần 2,66	Neo trực tiếp
zone_factor[z]	0,6–1,6	p10–p90: 0,16–2,06 (Manhattan 0,26–1,81)	Neo trực tiếp theo vùng chọn
lam_base (theo hex)	174 rider/cell	Manhattan 11/01/2015: 42 chuyển/ô res 8/giờ (trung vị), 206 ở res 7	Neo sau khi chọn độ phân giải
ride_len_L	14 phút	Trung vị 15,7; trung bình 19,6 (6–23h)	Neo trực tiếp ; trần công suất $\propto 1/(w_0 + L)$ sẽ giảm
pickup_w0	4,0 phút	ETA trung vị 3,3; p25 ETA theo cell 2,7	Neo ở khoảng 2,7–3,0 (ETA khi dư cung)
kappa_eta	1,3	Độ co giãn ETA theo cầu 0,35 (0,21 $\rightarrow$ 0,50 theo độ đông)	Mục tiêu so khớp qua simulator
sigma_u / shock ngày	0,35	SD log cầu theo ngày 0,12; $\approx$ 24% phương sai log ETA riêng từng ngày	Mục tiêu so khớp ; thêm shock cung theo ngày
base_supply, supply_hour_scale	19; 0,55	Không quan sát; xe bận 7,1 $\rightarrow$ 17,1 nghìn (6h $\rightarrow$ 17h); utilization bận 0,69	Suy gián tiếp; dùng utilization làm ràng buộc
tau_cancel, cancel_c0/c1	9 phút; 2,6; 1,2	Không có	Lấy từ tài liệu; phân tích độ nhạy
alpha (độ mạnh voucher)	4,0	Không có	Đối chiếu độ co giãn giá trong tài liệu

6.2. Quy trình hiệu chỉnh đề xuất (so khớp moment)

- Chọn vùng và đơn vị không gian.** Với Manhattan, dựng cầu ở H3 res 8 (xấp xỉ cỡ taxi zone) và dùng res 7 (hoặc cụm zone) làm đơn vị switchback. Với toàn thành phố, dùng zone hoặc res 7.
- Neo phía cầu** từ HVFHV: hour_factor (tách ngày thường/cuối tuần), zone_factor và lam_base theo diện tích ô. Có thể thay Poisson tổng hợp bằng thời điểm và vị trí request thật như Farias và cộng sự. Covariate của rider vẫn phải sinh tổng hợp.

3. **Neo thời gian:** `ride_len_L` từ thời gian chờ; `pickup_w0` từ các cell dư cung (p25 ETA theo cell). Tốc độ 11–12 mph dùng để quy đổi khoảng cách thành thời gian đón.
4. **So khớp độ căng** (không cấm thẳng): chạy simulator và tính trên dữ liệu mô phỏng đúng ba thống kê đã tính cho NYC: độ co giãn ETA theo cầu (mục tiêu 0,35; quý đông 0,50), phần phương sai log ETA thuộc về ngày ($\approx 0,24$), và phân phối tỷ lệ chờ trên 10 phút theo cell (p50 $\approx 9\%$, p95 $\approx 22\%$). Chính `kappa_eta`, biên độ shock cung theo ngày và `base_supply` tới khi khớp.
5. **Giữ nguyên và làm độ nhạy** với các tham số không có dữ liệu: `alpha`, tham số huỷ, `supply_factor`. Mọi kết luận vẫn kèm điều kiện “trong mô phỏng này”.

6.3. Chuyển từ taxi zone sang hex

Bảng 14: Các cách chuyển dữ liệu sang lưới hex

Cách	Khi nào	Lưu ý
Dùng thẳng tọa độ (yellow $\leq$ 06/2016)	Cần đúng bộ Farias, cần hex chính xác	Dữ liệu cũ 10 năm; taxi vẫy, không phải app
Rải điểm ngẫu nhiên trong zone rồi gọi <code>h3.latlng_to_cell</code>	HVFHV, simulator cấp request	Giữ được từng chuyển
Chia theo tỷ lệ diện tích zone $\cap$ hex	HVFHV, simulator cấp cell	Giả định mật độ đều, sai với công viên, sân bay
Không gán theo tâm ô	—	Ở res 7, 136/262 zone không được ô nào nhận

6.4. Những việc không nên làm với bộ dữ liệu này

- Train mô hình uplift, tính Qini hay $V(\pi)$ trên NYC: không có voucher, không có rider.
- Coi số chuyển là cầu: đó là throughput, đã bị cắt ở trần cung.
- Hiệu chỉnh độ căng từ so sánh cắt ngang giữa các zone: dấu bị ngược ($-0,07$ so với $+0,35$).
- Cấm thẳng độ co giãn 0,35 vào `kappa_eta`: hai đại lượng khác định nghĩa, phải so khớp qua simulator.
- Ngoại suy con số NYC sang thị trường Việt Nam: thứ chuyển giao được là *hình dạng và cơ chế*, không phải con số.

7. Kết luận

Bảng 15: Kết luận về khả năng sử dụng theo mục đích

Mục đích	Kết luận	Lý do
Train, đánh giá uplift ($\hat{\tau}$, Qini, AUUC)	Không dùng được	Không có voucher, không có đặc trưng rider
Đo $V(\pi)$, GTE, độ chệch A/B	Không dùng được	$V(\pi)$ không quan sát được; không có can thiệp
Hiệu chỉnh phía cầu và thời gian (hour_factor, zone_factor, lam_base, ride_len_L, pickup_w0)	Dùng được, neo trực tiếp	Có mốc đặt, tới, đón; 20 triệu chuyến/tháng
Hiệu chỉnh độ căng (kappa_eta, shock ngày, utilization)	Dùng được qua so khớp moment	Đo được độ co giãn ETA và biến động theo ngày
Hiệu chỉnh cung theo cell, tham số huỷ, độ mạnh voucher	Không, hoặc gián tiếp	Không có tài xế rảnh, request huỷ, khuyến mãi
Xương sống cầu cho simulator hex	Dùng được	Đúng cách Farias dựng simulator Manhattan
Kiểm tra ngoài bằng simulator Farias	Dùng được	Yellow 11/01/2015 tải được; code Farias đã chạy được
Kiểm tra code uplift trên dữ liệu thật	Dùng Hillstrom/Criteo	RCT có sẵn treatment và outcome

Kết luận chung

NYC TLC **không** thay được simulator, nhưng **dùng được để hiệu chỉnh tham số simulator**. Đây đúng là vai trò mentor đặt ra: xây dựng mô phỏng trước, dùng dữ liệu thật để neo.

8. Giới hạn và rủi ro

- **Một tháng dữ liệu** (07/2026, mùa hè). Các con số hiệu chỉnh nên lặp lại cho 2–3 tháng khác, nhất là mùa đông.
- **Chỉ có chuyến hoàn thành.** Mọi hệ số tính từ số chuyến có thể đánh giá thấp phản ứng thật của cầu.
- **Tương quan, không phải nhân quả.** Độ co giãn ETA – cầu bị nhiễu bởi thời tiết và sự kiện.
- **NYC khác Việt Nam** về mật độ, phương tiện (ô tô so với xe máy), giá và quy định lương tài xế.
- **Giấy phép.** NYC là dữ liệu công khai của thành phố; Criteo dùng CC BY-NC-SA 4.0 (phi thương mại); Hillstrom không ghi giấy phép.

A. Tái lập kết quả

Mọi con số trong báo cáo được tự tính bằng các script trong day25_9/eda/; bảng gốc ở eda/tables/, hình ở eda/figures/. Bảng cell đã xử lý lưu ở data/processed/cells_hvfhv_2026-07.parquet.

Bảng 16: Các script phân tích và thời gian chạy

00_download_data.py	Tải dữ liệu thô vào data/raw (khoảng 0,9 GB)
01_eda_hvfhv.py	Chất lượng, phân phối, thời gian, không gian (khoảng 2,5 phút)
02_supply_demand_hvfhv.py	Cell panel, phân rã phương sai, độ co giãn, định luật Little, bảng neo tham số (khoảng 45 giây)
03_eda_yellow2015.py	Bộ của Farias, gán zone, hex H3 (khoảng 40 giây)
04_eda_uplift_hillstrom.py	Đối chứng bộ uplift

Lệnh chạy: `pip install -r requirements.txt`, sau đó `python 00_download_data.py --with-uplift` rồi lần lượt các script 01–04. Phụ lục A (bài báo và dữ liệu) và Phụ lục B (tư điển trường) nằm trong cùng thư mục.

Tài liệu

- [1] NYC Taxi & Limousine Commission. TLC Trip Record Data. <https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page>. Từ điển HVFHV và Yellow (18/03/2025); báo cáo tổng hợp tháng.
- [2] V. Farias, A. Li, T. Peng, A. Zheng. Markovian Interference in Experiments. NeurIPS, 2022.
- [3] Y. Hu, S. Wager. Switchback Experiments under Geometric Mixing. arXiv:2209.00197.
- [4] J. C. Castillo, D. Knoepfle, E. G. Weyl. Surge Pricing Solves the Wild Goose Chase. ACM EC, 2017.
- [5] R. Johari, H. Li, I. Liskovich, G. Y. Weintraub. Experimental Design in Two-Sided Platforms: An Analysis of Bias. *Management Science*, 2022.
- [6] N. Chamandy. Experimentation in a Ridesharing Marketplace. Lyft Engineering, 2016.
- [7] K. Hillstrom. The MineThatData E-Mail Analytics and Data Mining Challenge, 2008.
- [8] E. Diemert và cộng sự. A Large Scale Benchmark for Uplift Modeling (Criteo Uplift Dataset), 2018.
- [9] Uber H3. Bảng diện tích ô theo độ phân giải. <https://h3geo.org/docs/core-library/restable/>.